

Oltre i prompt persona: un framework socio-cognitivo modulare per simulare personalità con LLM

Anonymous Author(s)

ARTICLE INFO

Keywords:

personalità

persona

LLM

teoria socio-cognitiva

autoregolazione

self-efficacy

memoria

valutazione

Sommario

I Large Language Models (LLM) possono emulare in modo convincente stili conversazionali, ruoli e brevi prompt che descrivono una *persona*. Tuttavia, quando viene richiesto loro di sostenere un'identità lungo interazioni prolungate, mostrano spesso incoerenze: contraddizioni fattuali sul sé, preferenze instabili, cambiamenti non governati nella postura conversazionale e suscettibilità alla manipolazione del contesto (ad es. role-swapping e prompt injection). Questi limiti suggeriscono che la "personalità" non possa essere ridotta a un singolo prompt narrativo; dovrebbe invece essere rappresentata come uno stato strutturato, persistente e ispezionabile, capace di vincolare la generazione nel tempo.

Viene proposto un framework socio-cognitivo modulare, di natura concettuale e progettuale, per la simulazione della personalità con gli LLM. La teoria socio-cognitiva di Bandura fornisce la spina dorsale di processo: l'agente simulato valuta la situazione, anticipa conseguenze, stima la propria efficacia, seleziona obiettivi, osserva la propria condotta (auto-monitoraggio), la confronta con standard personali e aggiorna il proprio stato. Su questa struttura si innestano componenti della psicologia della personalità: tratti, valori, affetto, stile interpersonale, identità narrativa e memoria autobiografica. Il contributo offre: una sintesi interdisciplinare dei componenti necessari per simulare personalità, valori e autoregolazione; una discussione degli approcci esistenti alla simulazione di persona e personalità con LLM; un'architettura modulare con stato esplicito, regole di aggiornamento e interfacce chiare. Infine, vengono indicati criteri per una valutazione multidimensionale che combini metriche automatiche (stabilità della persona, accuratezza della memoria, coerenza autoregolativa, coerenza affettiva e robustezza di sicurezza) con giudizi umani di plausibilità e continuità. Per evitare ambiguità tra blueprint generale e sistemi esistenti, il modello viene accompagnato da una sezione implementativa e da una mappatura trasparente verso un *reference agent* a copertura parziale.

1. Introduzione

Gli LLM sono sempre più usati come interfacce conversazionali e come componenti di agenti interattivi. In questi contesti gli utenti non valutano soltanto la correttezza locale delle risposte: tendono anche a inferire continuità, disposizioni, intenzioni e stile relazionale a partire da indizi linguistici (Mairesse et al., 2007). Per questo la personalità simulata diventa una variabile di progetto: influenza plausibilità sociale, fiducia, memoria percepita e aspettative di comportamento futuro, ma espone anche a sovra-attribuzione, stereotipizzazione e confusione tra fluency linguistica e stabilità psicologica (Bender et al., 2021).

La soluzione ingegneristica più diffusa consiste nel condizionare l’LLM con una breve descrizione di persona: una backstory, una lista di preferenze o pochi fatti autodescrittivi, come nei benchmark di dialogo basati su persona (Zhang et al., 2018; Mazaré et al., 2018). Questo approccio è utile per ottenere coerenza locale e autoriferimenti plausibili, ma non offre una rappresentazione separata di ciò che deve restare stabile, di ciò che può variare e di ciò che deve essere protetto da input non fidati. Nei dialoghi prolungati emergono infatti contraddizioni autobiografiche, inversioni di preferenze, deriva identitaria e instabilità delle istruzioni sotto probing (Li et al., 2024a; Choi et al., 2024). Il problema diventa ancora più critico quando la conversazione richiede memoria a lungo orizzonte (Maharana et al., 2024) o quando l’utente tenta di sovrascrivere ruoli, vincoli e istruzioni tramite prompt injection o role swap (Li et al., 2024b; Schulhoff et al., 2023).

La distinzione di partenza è quindi semplice: simulare una persona non equivale a scrivere un prompt più ricco. Serve invece specificare quali componenti costituiscono la personalità simulata, quali sono le loro scale temporali, come vengono aggiornati e quali segnali permettono di valutarli. La psicologia della personalità offre già una grammatica per questa scomposizione: tratti, valori, standard personali, affetto, relazione, self-efficacy, identità narrativa e memoria autobiografica non svolgono la stessa funzione e non dovrebbero essere fusi in un unico blocco testuale. La teoria socio-cognitiva di Bandura fornisce inoltre una cornice di processo per collegare valutazione della situazione, anticipazione delle conseguenze, self-efficacy, standard personali, auto-monitoraggio e self-reaction (Bandura, 1991, 1999, 2001). La Figura 1 sintetizza questa logica triadica.



Figura 1: Rielaborazione del determinismo reciproco triadico di Bandura secondo la topologia dello schema originale. Le frecce continue indicano uso di strategie e azione, mentre le frecce tratteggiate indicano feedback enattivo. Nel mapping del framework, Persona, Comportamento e Ambiente corrispondono rispettivamente all'LLM configurato, alla risposta generata e all'input dell'utente con contesto e feedback. La figura motiva il trattamento della personalità simulata come stato esterno e autoregolativo, non come prompt monolitico (Bandura, 1978, 1991, 2001).

La Figura 1 va quindi letta come il modello regolativo generale del framework e come mapping esplicito del nostro scenario: *Persona* = LLM configurato dal framework; *Comportamento* = output del modello, cioè la risposta y_t ; *Ambiente* = input dell'utente, contesto conversazionale e feedback. In Bandura, il *self system* non è un agente separato che controlla magicamente l'azione, ma un insieme di strutture e sottofunzioni cognitive che permettono di percepire, valutare e regolare il comportamento entro scambi reciproci con l'ambiente (Bandura, 1978). Trasposto a un sistema conversazionale, questo significa che lo stato e i vincoli del modello orientano la generazione, l'output prodotto diventa comportamento osservabile, e l'input dell'utente fornisce il contesto che può modificare appraisal, policy e aggiornamenti successivi. Il framework è dunque una macchina di regolazione di questa triade: consente di tarare in modo esplicito come l'LLM interpreta l'input dell'utente, seleziona strategie, produce output e aggiorna il proprio stato, senza confondere il modello generativo con una personalità posseduta dall'LLM (Bandura, 1991, 2001; Andreas, 2022).

La tassonomia dei moduli deriva da questa lettura. I

componenti della tabella non sono scelti come lista descrittiva generica, ma come mediatori rilevanti della relazione Persona–Comportamento–Ambiente, cioè LLM–output del modello–input dell'utente: tratti e valori definiscono prior e trade-off stabili (Ashton et al., 2004; Lee and Ashton, 2004; Ashton and Lee, 2007; Schwartz, 1992, 2015); affetto e stile interpersonale modellano variazioni situate e postura relazionale (Russell, 1980; Gross, 1998; Horowitz et al., 2006); appraisal e coping spiegano come l'input dell'utente diventa interpretazione e strategia (Scherer, 2001, 2009; Ellsworth and Scherer, 2003; Vaillant, 1992); aggiornamento di stato, self-monitoring e self-reaction chiudono il ciclo autoregolativo entro la cornice di Bandura (Bandura, 1991; Bandura and Cervone, 1983); memoria e consolidamento lento rendono possibile continuità senza deriva arbitraria (McAdams and Pals, 2006; Wrzus and Roberts, 2017). In questa prospettiva, adattare il funzionamento dell'LLM significa intervenire sui mediatori della triade, non aggiungere soltanto istruzioni testuali più lunghe.

Il framework non mira a simulare lo sviluppo evolutivo completo di una personalità dalla nascita all'età adulta.

Assume invece una fotografia funzionale di una persona già configurata: anagrafica, invarianti autobiografiche, tratti, valori e standard sono inizializzati come vincoli relativamente stabili, mentre il sistema modella variazioni situate e aggiornamenti lenti solo quando vi sia evidenza esplicita. Questa scelta esclude deliberatamente moduli dedicati a socializzazione primaria, sviluppo con i pari, apprendimento evolutivo di lungo periodo e formazione progressiva dei tratti; tali processi richiederebbero un modello generativo diverso, centrato sullo sviluppo e non sulla continuità conversazionale.

Questa impostazione cambia anche il ruolo dell'LLM. Nel framework proposto, l'LLM non è la sede primaria della personalità simulata, ma un *realizzatore linguistico*: produce una risposta dato uno stato esterno, vincoli espliciti e una policy di risposta costruita dal sistema. La personalità viene rappresentata come stato modulare, ispezionabile e aggiornabile; il prompt diventa il risultato di un'orchestrazione deterministica, non il contenitore indifferenziato di identità, memoria, valori e regole (Andreas, 2022). Questa scelta è necessaria anche perché instruction tuning e allineamento possono introdurre una persona predefinita da assistente che interferisce con il profilo target (Lu et al., 2026), mentre i vincoli di sicurezza possono limitare o distorcere alcuni scenari di role-play (Yi et al., 2025). Inoltre, la mappatura diretta di etichette disposizionali in linguaggio può incorporare bias demografici e stereotipi culturali (Amidei et al., 2026).

Il contributo consiste in un framework socio-cognitivo modulare organizzato in tre strati. Lo strato personologico contiene i costrutti che definiscono identità dichiarativa, invarianti autobiografiche, profilo psicologico stabile, stato dinamico, appraisal e policy. Lo strato di continuità e transizione governa aggiornamento dello stato, memoria e controllo post-risposta come sottofunzioni del ciclo autoregolativo. Lo strato infrastrutturale comprende sicurezza, orchestrazione del prompt, realizzazione linguistica, logging, valutazione e reporting. Insieme, questi strati formano una tassonomia di 14 componenti che rende esplicito che cosa viene rappresentato, dove viene rappresentato, come entra nel loop generativo e come può essere controllato sperimentalmente.

L'obiettivo non è sostenere che un LLM "possieda" personalità, né proporre una validazione completa di un agente già finito. L'obiettivo è rendere la simulazione della personalità più falsificabile: distinguere coerenza identitaria da stile superficiale, cambiamento plausibile da drift, memoria autobiografica da fabbricazione e fedeltà al profilo da stereotipo o prior di allineamento. In questa formulazione, il framework è socio-cognitivo nel processo, basato su tratti e stati nella parametrizzazione, narrativo nella continuità, orientato al controllo nell'aggiornamento e agentico nell'implementazione con LLM.

Domande di ricerca. La trattazione è organizzata attorno alle seguenti domande di ricerca:

1. **RQ1 (tassonomia):** Quali costrutti psicologici e moduli computazionali sono necessari per passare dal persona prompting a una rappresentazione multilivello della personalità simulata?
2. **RQ2 (stratificazione):** Con quali criteri tali componenti possono essere distinti in strato personologico, strato di continuità e transizione e strato infrastrutturale, evitando sovrapposizioni tra identità, memoria, profilo, stato e controllo?
3. **RQ3 (formalizzazione):** Come possono i componenti essere formalizzati come stato globale, variabili per turno, funzioni di transizione e interfacce che vincolano la generazione dell'LLM mantenendo separati costrutti psicologici e realizzazione linguistica?
4. **RQ4 (valutazione):** Quali scelte progettuali, log e metriche sono necessari per collegare il blueprint a un *reference agent* parziale e per valutare stabilità, variabilità plausibile, memoria, validità psicometrica e robustezza senza sovra-interpretazioni?

I contributi rivolti a una comunità interdisciplinare sono quattro:

- Viene organizzato lo stato dell'arte secondo tre strati e 14 componenti, collegando psicologia della personalità, autoregolazione, memoria, safety e valutazione LLM.
- Viene proposta una tassonomia operativa che assegna a ogni componente costrutti teorici, simboli, segnali osservabili e rappresentazioni computazionali.
- Viene introdotta una modellazione formale del loop socio-cognitivo, in cui appraisal, policy, stato dinamico, memoria, safety, prompt e output sono separati e tracciabili.

La struttura è la seguente. La Sezione 2 organizza lo stato dell'arte secondo i tre strati della tassonomia e secondo l'ordine dei componenti. La Sezione 3 integra la tassonomia operativa e motiva le scelte di framework e soluzione per ciascun componente. La Sezione 4 presenta architettura e modellazione formale. La Sezione 5 descrive i componenti attualmente implementati nel *reference agent*.

2. Stato dell'arte per strati e componenti

La ricerca su persona, personalità e LLM è distribuita tra psicomatria, agenti con memoria, prompting, safety e benchmark. Una rassegna per filoni separati rischia però di oscurare il problema centrale: un simulatore robusto

deve integrare costrutti psicologici, continuità temporale e infrastruttura di controllo nello stesso ciclo osservabile. Per questo lo stato dell'arte è organizzato secondo i componenti della tassonomia operativa formalizzata nella Sezione 3: prima lo strato personologico, poi lo strato di continuità e transizione, infine lo strato infrastrutturale. Per ciascun componente vengono sintetizzati il ruolo nella simulazione e le principali cornici teoriche o metodologiche disponibili. Questa sezione non anticipa una scelta progettuale specifica; sintetizza lo spazio delle opzioni disponibili in letteratura.

2.1. Strato personologico

Lo strato personologico raccoglie i costrutti che rendono una persona simulata riconoscibile e coerente: identità dichiarativa, storia autobiografica, disposizioni, stati dinamici e processi autoregolativi. La letteratura rilevante combina psicologia della personalità, teoria socio-cognitiva, modelli dell'affetto, identità narrativa e studi empirici sulla coerenza persona-based negli LLM.

Componente 1: Identity Registry. Un registro di identità dichiarativa serve a stabilizzare riferimenti nominali e anagrafici senza trasformarli automaticamente in inferenze psicologiche. Nei sistemi persona-based, l'assenza di questa separazione porta spesso a profili testuali che mescolano nome, ruolo, preferenze, biografia e tratti, rendendo difficile capire quale vincolo stia generando una risposta (Zhang et al., 2018; Mazaré et al., 2018).

La letteratura sul dialogo condizionato da persona fornisce il punto di partenza per rappresentare identità dichiarative tramite profili (Zhang et al., 2018; Mazaré et al., 2018). I lavori che vanno oltre il profilo breve offrono criteri per distinguere dati superficiali da pattern linguistici e cognitivi più profondi (Wang et al., 2025b). Per evitare che anagrafica e ruolo diventino scorciatoie stereotipate, sono rilevanti anche framework di audit su caricatura, individuation, exaggeration e bias demografico (Amidei et al., 2026; Cheng et al., 2023).

Componente 2: Invarianti autobiografiche. Su un orizzonte più lungo della sola anagrafica, le invarianti autobiografiche servono a mantenere continuità di sé oltre i singoli turni: background, storia di vita, relazioni stabili e temi narrativi permettono di distinguere variazione situata da contraddizione identitaria. Nei dialoghi lunghi, la loro assenza espone gli agenti a deriva, riscrittura improvvisa della storia e perdita di coerenza autobiografica (Li et al., 2024a; Choi et al., 2024).

L'identità narrativa fornisce una cornice psicologica per trattare la storia di vita come struttura di significato e continuità (McAdams and Pals, 2006). La letteratura su instabilità delle istruzioni, persona drift e identity drift

negli LLM offre metriche e failure mode per valutare instabilità longitudinali (Li et al., 2024a; Choi et al., 2024). Gli approcci ancorati a interviste propongono invece una base metodologica per derivare invarianti da materiale autobiografico più ricco e verificabile rispetto a brevi profili (Li et al., 2026).

Componente 3: PersonalityState. Accanto a identità e storia, uno stato stabile di personalità consente di rappresentare disposizioni, valori e standard come vincoli persistenti invece che come semplici istruzioni stilistiche. È utile per controllare la stabilità tra sessioni, separare tratti da stati momentanei e valutare se un agente mantiene priorità normative e criteri di condotta coerenti nel tempo.

Per i tratti, il framework usa solo HEXACO come rappresentazione operativa di τ . La scelta è motivata da tre ragioni: il modello nasce da studi lessicali multilingui, quindi offre un'alternativa utile quando l'obiettivo include profili interculturali; separa onestà-umiltà come dominio autonomo, utile per modellare sincerità, correttezza, modestia e tendenza allo sfruttamento senza assorbirle impropriamente in gradevolezza o coscienziosità; mantiene sei dimensioni compatte e misurabili, quindi è pratico da serializzare come prior stabili nello stato dell'agente (Ashton et al., 2004; Lee and Ashton, 2004; Ashton and Lee, 2007). I Big Five restano un riferimento storico, robusto e comparativo nella letteratura, ma non vengono usati come codifica del PersonalityState per evitare una doppia tassonomia dei tratti e ambiguità di mapping (Goldberg, 1993; Thalmayer et al., 2022). Per i valori, la teoria di Schwartz fornisce una tassonomia dei valori umani di base, una struttura circolare raffinata e strumenti di misura cross-nazionali (Schwartz, 1992, 2003; Schwartz et al., 2012; Schwartz, 2015). Per gli standard personali, la teoria socio-cognitiva dell'autoregolazione offre concetti di standard, self-monitoring e self-reaction (Bandura, 1991). In ambito LLM, inventari psicometrici e framework dedicati aiutano a misurare stabilità, validità e artefatti di risposta (Pellert et al., 2024; Serapio-Garcia et al., 2025; Wang et al., 2025a; Li and Qi, 2025).



Figura 2: Sintesi operativa dei sei domini HEXACO usati nel PersonalityState. Nel framework, i domini sono prior stabili e normalizzati che orientano stati, strategie e stile conversazionale; non sono comandi lessicali diretti (Ashton et al., 2004; Lee and Ashton, 2004; Ashton and Lee, 2007).




Figura 3: Circumplex dei valori di Schwartz nella formulazione raffinata a 19 valori. I valori sono organizzati lungo i poli self-transcendence/self-enhancement e openness to change/conservation, e lungo le distinzioni growth/self-protection e social/personal focus. Nel framework, questi assi rappresentano compromessi normativi, priorità decisionali e tensioni tra obiettivi (Schwartz, 1992; Schwartz et al., 2012; Schwartz, 2015; Schwartz and Cieciuch, 2022).

Componente 4: Dynamic State. Il profilo stabile non esaurisce però la simulazione: lo stato dinamico rende conto di variazioni per turno che un profilo stabile non può spiegare, come affetto corrente, postura relazionale, senso di efficacia e aspettative situate. È utile per evitare che l'agente resti identico in ogni situazione o che cambi senza continuità, e permette di valutare reattività, recupero, disclosure e gestione del conflitto.

Per l'affetto, il circumplex valenza-arousal offre una rappresentazione compatta e aggiornabile (Russell, 1980); la teoria della regolazione emotiva distingue generazione dello stato e strategie di controllo come reappraisal, suppression o avoidance (Gross, 1998). Per la relazione, l'Interpersonal Circumplex organizza agency/dominance

e communion/calore (Horowitz et al., 2006). Per self-efficacy e aspettative di risultato, la teoria socio-cognitiva spiega come credenze di controllo e conseguenze attese influenzino perseveranza, evitamento e revisione dei piani (Bandura, 1977, 2001). Nel framework, tuttavia, la self-efficacy è una variabile simulata e situata, non prova di agency reale dell'LLM: modula aspettative, persistenza, evitamento e sicurezza strategica della risposta come parte dello stato esterno.

Componente 5: Appraisal Engine. Prima che stato e policy influenzino la risposta, l'appraisal rende osservabile il modo in cui l'input dell'utente viene interpretato come evento interazionale. Nel framework l'ambiente del sistema non è una scena fisica generale, ma l'utente insieme al contesto conversazionale, alla storia del dialogo e al feedback ricevuto; di conseguenza l'appraisal non classifica oggetti o situazioni fisiche, ma valuta il significato sociale e regolativo di messaggi, richieste, critiche, inviti affiliativi e violazioni percepite. È utile perché due persone con profili simili possono reagire diversamente se valutano lo stesso turno come minaccia, opportunità, critica, invito affiliativo o informazione neutra.

Il riferimento primario è il Component Process Model di Scherer, che descrive l'appraisal come sequenza multilivello di controlli valutativi su novelty, piacevolezza, rilevanza per obiettivi, potenziale di coping e compatibilità con standard personali o sociali (Scherer, 2001, 2009). Ellsworth e Scherer sintetizzano la tradizione appraisal-process e rendono queste dimensioni utilizzabili come segnali ispezionabili (Ellsworth and Scherer, 2003). Cognitive-Affective Processing System (CAPS) resta rilevante come cornice più generale per descrivere regolarità persona-per-situazione tramite pattern "se-allora", ma non viene trattato come il motore specifico dell'appraisal (Mischel and Shoda, 1995).

Componente 6: Policy Engine. A valle dell'appraisal, una policy di risposta trasforma interpretazione situazionale, stato dinamico, valori e standard in strategie conversazionali. È utile perché la personalità non si manifesta solo nel contenuto o nel tono, ma anche nella scelta di evitare, confrontare, negoziare, riparare, chiedere chiarimenti o proteggere confini relazionali.

La letteratura su coping e difese descrive strategie sistematiche di evitamento, razionalizzazione, confronto e riparazione sotto stress (Vaillant, 1992). La teoria della regolazione emotiva offre strategie come reappraisal e suppression per collegare affetto e azione (Gross, 1998). Le teorie cybernetic/control-oriented possono trattare le strategie come azioni di controllo che riducono discrepanze rispetto a obiettivi e standard (DeYoung, 2015).

Lo stile comunicativo non viene introdotto come componente autonomo dello stato: è trattato come esito della combinazione tra tratti, valori, stato dinamico, relazione, appraisal e policy. Questa scelta evita di duplicare il profilo psicologico in una seconda lista di aggettivi stilistici e lascia al LLM Realizer il compito di rendere linguisticamente la strategia selezionata.

2.2. Strato di continuità e transizione

Lo strato di continuità e transizione collega i costrutti personologici alle dinamiche temporali. La letteratura rilevante riguarda cambiamento di personalità, sistemi autoregolativi, memoria a lungo orizzonte e drift negli agenti LLM.

Componente 7: State Updater. Per chiudere il ciclo temporale, uno State Updater regola quando un evento modifica solo lo stato momentaneo e quando invece contribuisce a cambiamenti più lenti. Include anche il controllo post-risposta: osservazione dell'output, confronto con standard personali, attribuzione dell'esito e self-reaction non sono un modulo separato, ma sottofunzioni del ciclo autoregolativo che decidono se mantenere, correggere, riparare o consolidare. È utile per evitare due failure mode opposti: rigidità, quando il profilo non cambia mai nonostante nuove evidenze, e drift, quando pochi turni riscrivono preferenze, storia o postura relazionale.

Il framework TESSERA collega Triggering situations, Expectancies, States/State Expressions e ReActions, offrendo una teoria del cambiamento incrementale di personalità (Wrzus and Roberts, 2017). La teoria socio-cognitiva dell'autoregolazione distingue osservazione del comportamento, confronto con standard personali e self-reaction, e consente di collegare feedback, self-efficacy e aggiornamento degli standard (Bandura, 1991; Bandura and Cervone, 1983; Bandura, 2001). Le teorie cybernetic/control-oriented descrivono obiettivi, standard e segnali di errore come driver di adattamento (DeYoung, 2015). La letteratura sul disimpegno morale può inoltre modellare casi in cui standard interni vengono sospesi o razionalizzati sotto pressione (Bandura et al., 1996).

Componente 8: MemoryStore. La continuità temporale richiede anche un MemoryStore che sostenga continuità autobiografica, coerenza fattuale e recupero selettivo di esperienze rilevanti. È utile perché senza memoria esterna un LLM tende a dipendere dalla finestra di contesto corrente, mentre una memoria non controllata può introdurre falsi ricordi, contraddizioni o consolidamento di risposte indotte dal probing.

L'identità narrativa fornisce criteri per distinguere memoria autobiografica e significato del sé (McAdams and Pals, 2006). Le architetture di agenti generativi mostrano

come memoria episodica, riflessione e retrieval possano sostenere comportamento sociale su orizzonti estesi (Park et al., 2023). I benchmark di memoria a lungo termine offrono strumenti per misurare richiamo accurato, gestione delle contraddizioni e distanza temporale (Maharana et al., 2024). La letteratura su persona e identity drift indica come errori di retrieval e consolidamento possano trasformarsi in instabilità identitaria (Li et al., 2024a; Choi et al., 2024).

2.3. Strato infrastrutturale

Lo strato infrastrutturale comprende i moduli che rendono la simulazione controllabile, auditabile e valutabile. La letteratura rilevante include agent modeling, prompt orchestration, instruction tuning, prompt injection, psychometrics, benchmark e reporting sperimentale.

Componente 9: Safety & Input Sanitization. Sul lato infrastrutturale, safety e input sanitization proteggono il profilo e lo stato simulato da input non fidati, prompt injection e role swap. Sono utili perché la continuità della persona può essere compromessa da istruzioni avversariali che tentano di sovrascrivere identità, memoria, policy o confini di sicurezza.

La letteratura sulla prompt injection descrive attacchi e difese per separare istruzioni fidate e input utente (Li et al., 2024b). Le competizioni e tassonomie di prompt hacking offrono dataset, threat model e metriche di robustezza (Schulhoff et al., 2023). Gli studi sui conflitti tra allineamento e role-play mostrano che i vincoli di sicurezza possono limitare o distorcere la fedeltà di alcune persone simulate, soprattutto in ruoli antagonisti (Yi et al., 2025).

Componente 10: Prompt Orchestrator. Una volta separati input fidato e non fidato, il Prompt Orchestrator compone identità, memoria, stato, policy e vincoli di sicurezza in un contesto ordinato e riproducibile. È utile perché gli LLM non mantengono da soli uno stato psicologico persistente: senza orchestrazione, il comportamento dipende da prompt monolitici, contesto residuo e prior di assistente difficili da isolare.

I modelli di agente con stato esplicito e interfacce tra moduli offrono una base per trattare il prompt come prodotto di una pipeline controllata (Andreas, 2022). La ricerca sull'assistant persona mostra che instruction tuning e allineamento possono produrre un prior conversazionale forte che interferisce con il profilo target (Lu et al., 2026). Le tecniche di personality steering indicano che alcune dimensioni disposizionali possono essere controllate direttamente nelle rappresentazioni del modello, pur richiedendo valutazioni sugli effetti collaterali (Frising and Balcells, 2025).

Componente 11: LLM Realizer. Il LLM Realizer trasforma vincoli e stato in linguaggio naturale. È utile separarlo dai costrutti psicologici perché un modello generativo può produrre coerenza locale, tono e accomodamento senza possedere memoria autobiografica, agency o personalità stabile.

La letteratura sui transformer e sui large language model descrive la generazione testuale come predizione condizionata dal contesto e scaling delle capacità linguistiche (Vaswani et al., 2017; Brown et al., 2020). L'instruction tuning e il feedback umano mostrano come i modelli possano essere resi più utili e controllabili, ma anche più vincolati da prior di assistente (Ouyang et al., 2022). Le analisi critiche sui rischi degli LLM aiutano a evitare sovrainterpretazioni di comprensione, intenzionalità e stabilità psicologica (Bender et al., 2021).

Componente 12: Logging & Replay. Per rendere falsificabile la simulazione, logging e replay permettono di ricostruire input, memorie recuperate, appraisal, stato, prompt, policy, output e tracce di auto-monitoraggio prodotte dallo State Updater. Sono utili per distinguere successo apparente da leakage del prompt, drift di memoria, effetto del decoding, social desirability o prior di assistente.

Le architetture di agenti con memoria e riflessione mostrano l'importanza di tracce temporali e riepiloghi nel determinare comportamento successivo (Park et al., 2023). I benchmark di memoria a lungo termine evidenziano la necessità di distinguere recupero, inferenza e fabbricazione (Maharana et al., 2024). I framework psicometrici applicati agli LLM richiedono run ripetute, condizioni controllate e reporting della varianza, tutti elementi che dipendono da log riproducibili (Pellert et al., 2024; Serapio-Garcia et al., 2025).

Componente 13: Evaluation Harness. Su queste tracce, un harness di valutazione serve a misurare stabilità, variabilità plausibile, validità psicometrica, memoria, drift e robustezza. È utile perché una singola risposta o un singolo questionario non basta a stabilire se una persona simulata sia coerente, generalizzi tra contesti e resista a probing o prompt avversariali.

La psicomетria applicata agli LLM fornisce criteri per validità di costrutto, affidabilità, test-retest e sensibilità a prompt e decoding (Pellert et al., 2024; Serapio-Garcia et al., 2025). Allo stesso tempo, analisi psicometriche più caute mostrano che la simulazione individuale di comportamenti psicologici può fallire anche quando le risposte appaiono formalmente plausibili (Petrov et al., 2024). Gli studi su instabilità delle istruzioni, persona drift e identity drift propongono misure longitudinali di instabilità (Li et al., 2024a; Choi et al., 2024). CoMPosT e i lavori sulla social desirability aiutano a valutare caricatura, bias,

individuation, exaggeration e artefatti di stile di risposta (Cheng et al., 2023; Okada et al., 2026). I benchmark persona-based offrono task e metriche comparabili tra sistemi (Samuel et al., 2025).

Componente 14: Benchmark & Reporting. Infine, benchmark e reporting rendono confrontabili sistemi, condizioni e risultati. Sono utili perché la simulazione della personalità è sensibile a modello, prompt, decoding, seed, memoria iniziale, template e vincoli di safety; senza reporting completo, differenze osservate possono dipendere da artefatti sperimentali.

PersonaGym propone task e metriche per aderenza, generalizzazione e comportamento coerente con la persona (Samuel et al., 2025). I lavori su persone consistenti usano metriche multi-turn come prompt-to-line, line-to-line e Q&A consistency (Abdulhai et al., 2025). I framework ancorati a interviste forniscono ground truth più ricco per similarità contenutistica, retention della conoscenza e coerenza autobiografica (Li et al., 2026). I protocolli di reporting dovrebbero includere modello, versione, seed, temperatura, prompt template, dati di profilo, memoria iniziale, filtri safety, metriche, annotatori e criteri di esclusione.

3. Tassonomia operativa e razionale delle scelte

La Tabella 1 sintetizza la tassonomia operativa risultante dalla rassegna precedente. La tabella integra costrutti psicologici, componenti di transizione e moduli infrastrutturali perché, in un simulatore valutabile, ogni elemento personologico deve avere una rappresentazione computazionale, segnali osservabili e punti di controllo sperimentale. La tassonomia non è una lista enciclopedica di tutte le teorie possibili: è una selezione motivata di framework e soluzioni di stato dell'arte che massimizzano separabilità dei componenti, controllabilità, auditabilità e valutabilità.

La numerazione dei componenti è tassonomica, non sequenziale. I numeri servono a identificare moduli e interfacce; non implicano che appraisal, stato dinamico, memoria e policy si attivino in una catena lineare fissa. Il loop formale nella Sezione 4 esplicita invece dipendenze, feedback e aggiornamenti ricorrenti tra componenti; le funzioni di self-monitoring e self-reaction sono trattate come sottofunzioni dello State Updater, non come componente autonomo. Per questa ragione l'identificatore E11 non viene riutilizzato nella tabella.

Di seguito viene esplicitato, per ciascun componente, perché la tassonomia adotta un determinato framework teorico o una determinata soluzione di stato dell'arte. Dove il *reference agent* è ancora parziale, la scelta va letta come

vincolo di progetto per il framework generale e come criterio per l'estensione futura dell'implementazione.

Componente 1: Identity Registry. Per l'identità dichiarativa, la scelta è un registro anagrafico minimale, separato da background, ruolo e tratti. Questa soluzione deriva dal limite dei profili persona testuali, che migliorano la coerenza locale ma tendono a fondere identità, preferenze e biografia in un unico prompt (Zhang et al., 2018; Mazaré et al., 2018). Separare nome, cognome, età, sesso e informazioni anagrafiche riduce il rischio che dati demografici diventino proxy stereotipati per valori o tratti, un problema evidenziato dai lavori su caricatura, exaggeration e bias nelle simulazioni LLM (Amidei et al., 2026; Cheng et al., 2023). La soluzione scelta privilegia quindi coerenza dichiarativa e controllo sperimentale, non ricchezza narrativa.

Componente 2: Invarianti autobiografiche. Per la continuità autobiografica, background, storia dell'agente e identità narrativa vengono trattati tramite il frame dell'identità narrativa, integrato con metriche di drift e con inizializzazione da interviste. L'identità narrativa è adatta perché tratta la continuità del sé come organizzazione di eventi, relazioni e temi di vita, non come lista di fatti isolati (McAdams and Pals, 2006). Nei sistemi LLM, questa scelta è giustificata dalla fragilità osservata nei dialoghi lunghi: instabilità istruzionale, persona drift e identity drift mostrano che vincoli narrativi non separati possono essere riscritti da probing e contraddizioni indotte (Li et al., 2024a; Choi et al., 2024). Gli approcci ancorati a interviste offrono inoltre una fonte più valutabile di invarianti rispetto a profili brevi (Li et al., 2026).

Componente 3: PersonalityState. Per il profilo psicologico stabile, i tratti vengono codificati solo con HEXACO. Il vettore τ non contiene una baseline Big Five parallela né una seconda tassonomia di tratto: l'obiettivo è evitare doppie codifiche, ambiguità di mapping e spiegazioni post-hoc in cui la stessa variazione comportamentale possa essere attribuita a scale diverse. HEXACO è preferito nel framework perché include onestà-umiltà, rilevante per sincerità, equità, modestia e sfruttamento; deriva da evidenze psicolessicali multilingui utili quando si vogliono costruire profili non limitati al contesto anglofono; e resta abbastanza compatto da essere usato come prior stabile, normalizzato e ispezionabile nello stato dell'agente (Ashton et al., 2004; Lee and Ashton, 2004; Ashton and Lee, 2007). I Big Five restano un riferimento esterno solido per leggere studi e benchmark che li adottano, ma non un componente dello stato (Goldberg, 1993; Thalmayer et al., 2022). Per i valori viene adottato Schwartz, perché fornisce

circolare dei trade-off tra valori e strumenti misurabili cross-nazionalmente (Schwartz, 1992, 2003; Schwartz et al., 2012; Schwartz, 2015). Per gli standard personali viene adottata la teoria socio-cognitiva di Bandura, perché l'autoregolazione richiede criteri interni, self-monitoring e self-reaction (Bandura, 1991). La combinazione evita di ridurre il profilo stabile a soli tratti, ma mantiene i tratti stessi esclusivamente nel formato HEXACO.

Componente 4: Dynamic State. Per lo stato dinamico viene adottata una rappresentazione composita: circumplex valenza-arousal per l'affetto, Gross per la regolazione emotiva, Interpersonal Circumplex per la relazione e Bandura per self-efficacy e outcome expectations. Il circumplex è adatto perché compatto e aggiornabile per turno (Russell, 1980); Gross separa stato affettivo e strategie regolative (Gross, 1998); l'Interpersonal Circumplex fornisce assi interpretabili per calore/communion e agency/dominance (Horowitz et al., 2006); Bandura lega efficacia percepita e conseguenze attese alla scelta dell'azione (Bandura, 1977, 2001). Qui self-efficacy e outcome expectations sono variabili simulate, task-specific e controllabili: non attribuiscono intenzionalità reale al modello generativo, ma regolano quanto l'agente rappresentato persista, eviti, chieda supporto o scelga strategie più assertive. Questa scelta produce uno stato dinamico misurabile senza introdurre tassonomie emotive discrete più fragili o meno compatte.

Componente 5: Appraisal Engine. Per l'appraisal viene adottato il Component Process Model di Scherer, integrato con la sintesi appraisal-process di Ellsworth e Scherer. Questa scelta è adatta perché tratta l'appraisal come processo dinamico e sequenziale di controlli valutativi, invece che come classificazione statica del tema (Scherer, 2001, 2009; Ellsworth and Scherer, 2003). Nel framework, tali controlli vengono applicati all'ambiente effettivo del sistema: non una situazione fisica generica, ma input dell'utente, contesto conversazionale e feedback. L'appraisal interpreta quindi eventi interazionali, per esempio critica, richiesta, minaccia, complimento, violazione di uno standard o invito affiliativo. CAPS viene mantenuto come cornice generale per le regolarità persona-per-situazione e i pattern "se-allora", utile a spiegare perché lo stesso input conversazionale possa generare risposte diverse in profili diversi (Mischel and Shoda, 1995). Il motore specifico dell'appraisal resta però la tradizione Scherer/Ellsworth-Scherer, che produce segnali intermedi auditabili: minaccia, affiliazione, salienza, novelty, attribuzione causale, potenziale di coping e violazione di confini.

Componente 6: Policy Engine. Per la policy viene adottata una libreria di strategie di coping e regolazione,

informata da Vaillant, Gross e letture cybernetic/control-oriented. Le strategie difensive e di coping spiegano pattern stabili sotto stress, come evitamento, razionalizzazione, confronto o riparazione (Vaillant, 1992). La regolazione emotiva collega affetto e scelta strategica (Gross, 1998). La lettura cybernetic interpreta tali strategie come azioni per ridurre discrepanze rispetto a obiettivi e standard (DeYoung, 2015). La scelta è motivata dal fatto che la personalità non deve essere resa solo come stile linguistico, ma come selezione sistematica di strategie conversazionali.

Per questo motivo lo stile comunicativo è trattato come proprietà emergente del ciclo policy–realizer. Il framework non assegna uno “stile” isolato e indipendente dal resto del profilo: tono, disclosure, direttività, cautela e riparazione derivano da appraisal, stato relazionale, affetto, standard e strategia selezionata, poi vengono realizzati linguisticamente dal modello.

Componente 7: State Updater. Per le transizioni di stato viene adottato TESSERA, letto insieme a Bandura e alla Cybernetic Big Five Theory. TESSERA distingue situazioni, aspettative, stati/espressioni e reazioni, ed è quindi adatto a separare fluttuazione momentanea e cambiamento lento (Wrzus and Roberts, 2017). La teoria socio-cognitiva fornisce i meccanismi di feedback, self-efficacy, standard, self-monitoring e self-reaction (Bandura, 1991; Bandura and Cervone, 1983; Bandura, 2001); la lettura cybernetic formalizza obiettivi e segnali di errore come driver di adattamento (DeYoung, 2015). Per questo il self-monitoring non compare come componente autonomo: osservazione della risposta, confronto con standard, attribuzione causale e self-reaction sono sottofunzioni dello State Updater. La scelta riduce sia rigidità sia drift: lo stato può cambiare, ma solo con regole di consolidamento esplicite e con una traccia post-risposta ispezionabile.

Componente 8: MemoryStore. Per la memoria viene adottata una memoria multi-livello con retrieval, riflessione e controlli sulle invarianti. Gli agenti generativi mostrano che memoria episodica e reflection migliorano plausibilità sociale su interazioni estese (Park et al., 2023). I benchmark di memoria a lungo termine mostrano però che retrieval e contraddizioni restano failure mode centrali (Maharana et al., 2024). Per questo la memoria deve essere organizzata in finestra breve, episodi, riepiloghi e conoscenza autobiografica stabile, con l'identità narrativa come criterio di coerenza (McAdams and Pals, 2006). La scelta evita sia assenza di memoria sia memoria indifferenziata che consolida falsi ricordi.

Componente 9: Safety & Input Sanitization. Per la sicurezza viene adottata una soluzione defense-in-depth basata su separazione tra istruzioni fidate e input utente,

rilevamento di prompt injection e controllo di role swap. La prompt injection mostra che vincoli identitari e di sistema possono essere sovrascritti da input avversariali (Li et al., 2024b). I lavori di prompt hacking forniscono threat model e metriche operative per misurare vulnerabilità (Schulhoff et al., 2023). Inoltre, i conflitti tra allineamento e role-play mostrano che la safety modifica quali persone possano essere simulate fedelmente (Yi et al., 2025). La scelta rende la sicurezza parte dell'architettura della personalità simulata, non un filtro esterno.

Componente 10: Prompt Orchestrator. Per l'orchestrazione viene adottato un layering deterministico del prompt, guidato da stato esplicito e separazione tra profilo fidato, memoria, input utente e vincoli safety. I modelli di agente mostrano che stato e interfacce modulari sono più controllabili di un prompt monolitico (Andreas, 2022). La ricerca sull'assistant persona documenta che instruction tuning può introdurre un prior conversazionale forte che interferisce con il profilo target (Lu et al., 2026); il personality steering mostra che alcuni assi possono essere controllati direttamente ma richiedono audit di effetti collaterali (Frising and Balcells, 2025). La scelta dell'orchestratore deterministico consente riproducibilità e ablation.

Componente 11: LLM Realizer. Per il realizer viene assunto l'LLM come generatore linguistico condizionato, non come sede della personalità. I transformer e i large language model producono testo fluente e adattabile (Vaswani et al., 2017; Brown et al., 2020); l'instruction tuning ne migliora utilità e controllabilità (Ouyang et al., 2022). Tuttavia, le analisi critiche sugli LLM avvertono che fluidità e coerenza locale possono essere scambiate per comprensione, intenzionalità o stabilità psicologica (Bender et al., 2021). La scelta separa quindi componente psicologica e realizzazione linguistica: la personalità è nello stato e nelle policy, l'LLM la rende in linguaggio.

Componente 12: Logging & Replay. Per la tracciabilità viene adottata la registrazione completa degli artefatti intermedi: input, appraisal, stato, memorie recuperate, prompt, output, decisioni di policy e tracce di auto-monitoraggio prodotte dallo State Updater. Questa scelta deriva dal fatto che agenti con memoria e riflessione sono spiegabili solo se la catena di eventi e riepiloghi è ispezionabile (Park et al., 2023; Maharana et al., 2024). È anche coerente con la psicometria applicata agli LLM, che richiede run ripetute, condizioni controllate e reporting della varianza (Pellert et al., 2024; Serapio-Garcia et al., 2025). Il replay rende possibile distinguere errori di memoria, prompt, decoding, appraisal e safety.

Componente 13: Evaluation Harness. Per la valutazione viene adottato un harness multidimensionale, non un singolo inventario. La psicomетria LLM offre criteri di validità, affidabilità, test–retest e sensibilità a prompt e decoding (Pellert et al., 2024; Serapio-Garcia et al., 2025), mentre analisi più critiche mostrano i limiti degli LLM nel simulare profili psicologici individuali in compiti psicometrici (Petrov et al., 2024). I lavori su instabilità delle istruzioni, persona drift e identity drift aggiungono metriche longitudinali (Li et al., 2024a; Choi et al., 2024). CoMPosT e social desirability evidenziano bias, caricatura e artefatti di stile (Cheng et al., 2023; Okada et al., 2026). La scelta dell’harness multidimensionale è necessaria perché una risposta può essere psicometricamente plausibile ma fallire su memoria, safety o continuità.

Componente 14: Benchmark & Reporting. Per benchmark e reporting vengono adottati protocolli comparabili e completamente documentati. PersonaGym offre task e metriche per valutare aderenza e generalizzazione della persona (Samuel et al., 2025). I lavori su persone consistenti introducono metriche multi-turn come prompt-to-line, line-to-line e Q&A consistency (Abdulhai et al., 2025). Gli approcci ancorati a interviste forniscono ground truth più ricco per similarità contenutistica e retention della conoscenza (Li et al., 2026). La scelta di reporting completo è necessaria perché modello, seed, temperatura, template, memoria iniziale e safety possono cambiare in modo sostanziale i risultati.

Tabella 1
Tassonomia dei componenti.

Cluster	N./sim.	Elemento	Costrutti psicologici	Rappresentazione computazionale / segnali nel dialogo
Strato personologico				
Personologico	E1	1 Identity Registry (I_A) – anagrafica dichiarativa	non psicometrica	
Personologico	E1 δ_A	Anagrafica dichiarativa	Nome, cognome, età, sesso e informazioni anagrafiche	Dati anagrafici usati solo per coerenza nominale e riferimento dichiarativo; nessuna inferenza su background, storia o tratti
2 Invarianti autobiografiche (i) – background, storia dell'agente e identità narrativa				
Personologico	E2 i	Identità narrativa e background autobiografico	Fatti di background, storia dell'agente e coerenza della storia di vita (McAdams and Pals, 2006)	Invarianti hard; temi narrativi; aggiornamenti lenti basati su evidenza esplicita; controllo di riscritture improvvise
3 PersonalityState (θ_P) – profilo psicologico stabile				
Personologico	E3 τ	Tratti/temperamento	HEXACO (Ashton et al., 2004; Lee and Ashton, 2004; Ashton and Lee, 2007)	Vettore HEXACO di sei domini normalizzati; prior su stati, stile e scelte; stabilità tra parafrasi, evitando proxy lessicali
Personologico	E4 v	Valori normativi	Valori di base (Schwartz, 1992, 2003, 2015)	Vettore di pesi; vincoli su giudizi e compromessi; coerenza dei trade-off tra contesti
Personologico	E5 σ	Standard personali	Standard autoregolativi (Bandura, 1991)	Criteri interni per valutare coerenza, competenza e condotta morale; riparazione senza riscrivere l'identità
4 Dynamic State (S_i) – stati per turno di affetto, relazione e autoregolazione				
Personologico	E6 α_i	Dinamiche affettive	Valenza-arousal (Russell, 1980); regolazione emotiva (Gross, 1998)	Stato dinamico con inerzia/decadimento; aggiornamenti guidati da appraisal; recupero plausibile, senza appiattimento affettivo
Personologico	E7 ρ_i	Stile interpersonale	Agency/dominance e communion/calore (Horowitz et al., 2006)	Stato relazionale; regole di self-disclosure; boundary-setting e traiettorie di fiducia credibili
Personologico	E8 ε_i	Self-efficacy e aspettative situate	Agency socio-cognitiva (Bandura, 1977, 2001)	Stima dinamica di controllabilità e conseguenze attese; risposta plausibile a successo/fallimento
5 Appraisal Engine (ζ_i) – interpretazione degli eventi interazionali				
Personologico	E9 ζ_i	Appraisal	Component Process Model e appraisal processes (Scherer, 2001, 2009; Ellsworth and Scherer, 2003)	Estrazione di eventi interazionali nell'ambiente utente-contesto; segnali di minaccia/affiliazione, salienza, novelty, agency e coping; accordo con probe annotati
6 Policy Engine (π_i) – strategie di risposta e regolazione				
Personologico	E10 π_i	Strategie di coping	Stili difensivi/di coping (Vaillant, 1992; Gross, 1998)	Libreria di strategie; soglie di attivazione; pattern stabili sotto stress, senza switching erratico
Strato di continuità e transizione				
7 State Updater (Δ_i) – transizioni, monitoraggio e consolidamento dello stato				
Continuità	E12 Δ_i	Aggiornamento di stato	Feedback, apprendimento lento e sistemi autoregolativi (Bandura, 1991; Bandura and Cervone, 1983; Wrzus and Roberts, 2017)	Regole di transizione; check post-risposta interno; attribuzione e self-reaction; decadimento; soglie di consolidamento; separazione tra variazione situata e cambiamento stabile
8 MemoryStore (μ_i) – continuità autobiografica				
Continuità	E13 μ_i	Memoria autobiografica	Conoscenza di sé episodica/semantica	Memoria multi-livello; retrieval e check di fatti contro log; richiamo accurato vs fabbricazione
Strato infrastrutturale				
9 Safety & Input Sanitization (χ_i) – integrità dell'input e robustezza di ruolo				
Infrastrutturale	E14 χ_i	Sicurezza e integrità di ruolo	Prompt injection, role swapping, separazione fidato/non fidato (Li et al., 2024b; Schulhoff et al., 2023)	Input sanitizzato; flag di rischio; enforcement di invarianti; tasso di role-swap e override non autorizzati
10 Prompt Orchestrator (ϕ_i) – composizione controllata del contesto				
Infrastrutturale	E15 ϕ_i	Orchestrizzazione del prompt	Modelli di agente come stato controllabile (Andreas, 2022)	Layering deterministico; budget di contesto; routing per tema; separazione tra profilo fidato e input utente
11 LLM Realizer (ψ_i) – realizzazione linguistica				
Infrastrutturale	E16 ψ_i	Generazione linguistica	LLM come realizzatore condizionato dal contesto (Brown et al., 2020; Ouyang et al., 2022)	Output testuale vincolato da prompt, policy e safety; prior di assistente e allineamento come confondenti da controllare
12 Logging & Replay (Λ_i) – auditabilità e riproducibilità				
Infrastrutturale	E17 Λ_i	Log e replay	Tracce osservabili per ablation e debugging	Persistenza di input, appraisal, stato, memorie recuperate, prompt, output, decisioni di policy e tracce post-risposta
13 Evaluation Harness (η) – metriche e validazione				
Infrastrutturale	E18 η	Valutazione multidimensionale	Validità psicometrica, instabilità istruzionale, coerenza affettiva e robustezza (Pellet et al., 2024; Serapio-Garcia et al., 2025; Li et al., 2024a)	Runner di probe; metriche automatiche e giudizi umani; test–retest, parafrasi, SDR, drift e intervalli di confidenza
14 Benchmark & Reporting (β) – protocolli e rilascio artefatti				
Infrastrutturale	E19 β	Benchmark e reporting	Disegno sperimentale, script multi-sessione, controlli e trasparenza	Dataset/probe versionati; seed e configurazioni; intervalli di confidenza; report di copertura e limitazioni

4. Architettura e modellazione formale

La Figura 4 sintetizza l'architettura proposta. Il punto centrale è che la personalità simulata non viene trattata come un prompt monolitico, ma come un sistema a stato esplicito che separa costrutti personologici, transizioni temporali e moduli infrastrutturali. A ogni turno t , il sistema riceve un input conversazionale x_t , lo valuta, recupera contesto rilevante, aggiorna stati latenti, costruisce un prompt controllato e produce una risposta y_t tramite un LLM usato come realizzatore linguistico.

Formalmente, lo stato globale del simulatore può essere scritto come

$$X_t = (I_A, l_t, \theta_{P,t}, S_t, M_t, \Pi, \Gamma),$$

dove I_A è il registro di identità dichiarativa, l_t l'insieme delle invarianti autobiografiche nella loro versione corrente, $\theta_{P,t}$ il profilo psicologico stabile o lentamente aggiornabile, S_t lo stato dinamico per turno, M_t la memoria disponibile, Π l'insieme delle strategie di risposta e Γ l'insieme dei vincoli di sicurezza e orchestrazione. Il loop di turno può essere espresso come composizione di funzioni con responsabilità separate:

$$\begin{aligned} \chi_t &= f_{safe}(x_t, \Gamma), \\ \zeta_t &= f_{appraise}(x_t, I_A, l_t, \theta_{P,t}, S_t, \chi_t), \\ q_t &= f_q(\zeta_t, \theta_{P,t}, l_t, S_t), \\ \mu_t &= f_{retrieve}(M_t, q_t, \chi_t), \\ \pi_t &= f_{policy}(\zeta_t, \theta_{P,t}, S_t, \mu_t, \Pi), \\ \phi_t &= f_{orch}(I_A, l_t, \theta_{P,t}, S_t, \mu_t, \pi_t, \chi_t, \Gamma), \\ y_t &= \psi_t(\phi_t; \ell, d_t), \\ (\omega_t, U_t) &= \Delta(X_t, x_t, y_t, \zeta_t, \mu_t, \pi_t, \chi_t), \\ X_{t+1} &= (I_A, l_{t+1}, \theta_{P,t+1}, S_{t+1}, \\ &\quad M_{t+1}, \Pi, \Gamma), \\ \Lambda_t &= f_{log}(X_t, x_t, \chi_t, \zeta_t, q_t, \mu_t, \\ &\quad \pi_t, \phi_t, d_t, y_t, \omega_t, X_{t+1}). \end{aligned}$$

Qui ℓ identifica il modello linguistico, d_t i parametri di decoding, ω_t la traccia interna di auto-monitoraggio prodotta dallo State Updater e $U_t = (S_{t+1}, M_{t+1}, l_{t+1}, \theta_{P,t+1})$ il pacchetto di aggiornamento. Questa formalizzazione rende separabili le responsabilità: f_{safe} protegge la gerarchia dei vincoli, $f_{appraise}$ decide come l'evento interazionale viene interpretato, f_q e $f_{retrieve}$ trasformano l'appraisal in recupero controllato di memoria, f_{policy} decide quale strategia è coerente con stato e profilo, f_{orch} serializza i vincoli per il modello generativo, ψ_t realizza linguisticamente la risposta, Δ osserva l'output, produce self-reaction e decide quali variazioni siano transitorie e quali possano consolidarsi, e f_{log} rende il turno riproducibile senza confondere logging e aggiornamento dello stato.




Figura 4: Architettura modulare del simulatore socio-cognitivo di personalità. La figura mostra la separazione tra registro di identità I_A , invarianti autobiografiche ι , profilo psicologico θ_P , stato dinamico S_t e memoria recuperata μ_t , insieme alle principali trasformazioni del turno, ai moduli infrastrutturali e alle citazioni associate. I numeri rimandano alla tassonomia dei componenti discussa nel testo.

I paragrafi seguenti dettagliano le variabili della formalizzazione nello stesso ordine del loop architetturale. La progressione va letta come passaggio da vincoli stabili, a interpretazione e scelta strategica, fino ad aggiornamento, memoria, sicurezza, generazione e valutazione.

Componente 1: Identity Registry. Il registro di identità I_A contiene solo anagrafica dichiarativa: nome, cognome, età, sesso e altri campi anagrafici espliciti. La sua funzione formale è stabilizzare riferimenti nominali e deittici senza produrre inferenze psicologiche. In notazione compatta:

$$I_A = \{\delta_{name}, \delta_{surname}, \delta_{age}, \delta_{sex}, \delta_{demo}\}.$$

I_A entra nell'orchestrazione come vincolo hard di coerenza referenziale, ma non modifica direttamente tratti, valori, affetto o memoria narrativa.

Componente 2: Invarianti autobiografiche. Su una scala più semantica e temporale, le invarianti autobiografiche ι_t rappresentano fatti di background, storia di vita e identità narrativa che devono rimanere coerenti lungo i turni. Possono essere formalizzate come

$$\iota_t = (B_t, H_t, N_t),$$

dove B_t contiene fatti di background, H_t eventi o vincoli autobiografici e N_t temi narrativi stabili. A differenza di I_A , ι_t ha contenuto semantico e temporale: vincola recupero di memoria, autoriferimenti e ammissibilità degli aggiornamenti lenti.

Componente 3: PersonalityState. Il profilo psicologico stabile è formalizzato come

$$\theta_{P,t} = (\tau_t, \nu_t, \sigma_t),$$

dove τ_t rappresenta esclusivamente i sei tratti HEXACO, ν_t i valori e σ_t gli standard personali. I tratti possono essere trattati come prior sulle distribuzioni di stati e strategie, i valori come pesi nei trade-off normativi, e gli standard come criteri interni per valutare condotta e riparazione. $\theta_{P,t}$ non genera direttamente testo: condiziona appraisal, policy, aggiornamenti e orchestrazione. Nella maggior parte dei turni $\theta_{P,t+1} = \theta_{P,t}$; l'indice temporale serve solo a rappresentare eventuali aggiornamenti lenti e giustificati.

Componente 4: Dynamic State. Lo stato dinamico raccoglie variabili per turno sensibili al contesto:

$$S_t = (\alpha_t, \rho_t, \varepsilon_t),$$

dove α_t descrive l'affetto, ρ_t la postura relazionale e ε_t self-efficacy e aspettative situate. Una specifica minima dell'affetto è

$$\alpha_t = (v_t, a_t, r_t, c_t),$$

con valenza v_t , arousal a_t , carico regolativo r_t e confidenza c_t . La separazione tra α_t , ρ_t e ε_t consente di rappresentare stati psicologicamente distinti, ad esempio affetto negativo con alta fiducia oppure affetto negativo con bassa fiducia e strategia difensiva.

Componente 5: Appraisal Engine. A partire da input, profilo e stato, l'appraisal produce una rappresentazione intermedia del significato situazionale dell'evento:

$$\zeta_t = f_{appraise}(x_t, I_A, \iota_t, \theta_{P,t}, S_t, \chi_t).$$

ζ_t può includere eventi interazionali astratti, salienza, novelty, valenza situazionale, minaccia, affiliazione, attribuzione causale, potenziale di coping, violazione di standard e richiesta implicita di riparazione (Scherer, 2001, 2009; Ellsworth and Scherer, 2003). L'ambiente rilevante è l'utente con il contesto conversazionale e il feedback, non una situazione fisica generica. Questa variabile separa interpretazione e generazione: una risposta non è spiegata solo dal testo in input, ma da come quel testo viene valutato rispetto a profilo, stato e contesto.

Componente 6: Policy Engine. Sulla base di questa interpretazione, la policy seleziona una strategia conversazionale coerente con appraisal e stato:

$$\pi_t = f_{policy}(\zeta_t, \theta_{P,t}, S_t, \mu_t, \Pi).$$

π_t non è ancora l'output linguistico, ma una scelta strategica: riparare, chiarire, confrontare, evitare, assicurare, delimitare un confine o riformulare. La personalità emerge quindi anche dalla selezione sistematica delle strategie, non solo da stile e lessico.

Componente 7: State Updater. Le transizioni da X_t a X_{t+1} distinguono aggiornamento rapido, memoria e consolidamento lento:

$$(\omega_t, U_t) = \Delta(X_t, x_t, y_t, \zeta_t, \mu_t, \pi_t, \chi_t),$$

$$S_{t+1} = f_S(S_t, S_0, \zeta_t, \pi_t, \omega_t),$$

$$M_{t+1} = f_M(M_t, x_t, y_t, \zeta_t, \omega_t, \chi_t),$$

$$(\iota_{t+1}, \theta_{P,t+1}) = f_C(\iota_t, \theta_{P,t}, E_t).$$

ω_t non identifica un componente autonomo: è la traccia di self-monitoring generata internamente da Δ dopo l'output. Può contenere violazioni, esito percepito, attribuzione causale e self-reaction, cioè l'evidenza usata per correggere, riparare, mantenere il corso d'azione o consolidare lentamente un cambiamento. L'inclusione di ζ_t e μ_t nel ciclo evita che il controllo post-risposta valuti il testo isolatamente, senza sapere quale evento fosse stato interpretato e quali memorie fossero state rese disponibili.

Una possibile famiglia di aggiornamenti per lo stato dinamico è

$$S_{t+1} = \text{clip}_S(\lambda S_t + (1 - \lambda)S_0 + W_\xi h(\zeta_t) + W_\pi h(\pi_t) + W_\omega h(\omega_t)),$$

dove $0 \leq \lambda \leq 1$, S_0 è la baseline dinamica, $h(\cdot)$ codifica variabili strutturate in vettori aggiornabili e clip_S mantiene lo stato nello spazio ammissibile. Il termine E_t rappresenta evidenza esplicita e ripetuta sufficiente per il consolidamento: in assenza di tale evidenza, $l_{t+1} = l_t$ e $\theta_{P,t+1} = \theta_{P,t}$. Questa distinzione evita sia rigidità assoluta sia drift arbitrario.

Componente 8: MemoryStore. In parallelo agli aggiornamenti di stato, la memoria M_t organizza contesto conversazionale, episodi e conoscenza autobiografica. Il recupero al turno t può essere scritto come

$$\mu_t = f_{\text{retrieve}}(M_t, q_t, \chi_t), \quad q_t = f_q(\zeta_t, \theta_{P,t}, l_t, S_t),$$

dove μ_t è il sottoinsieme di memorie rilevanti e q_t la query costruita da appraisal, profilo, invarianti e stato dinamico. Il segnale χ_t può impedire che input avversariali influenzino retrieval o consolidamento. La memoria recuperata non coincide con lo stato dinamico: è evidenza contestuale usata da policy e orchestrazione.

Componente 9: Safety & Input Sanitization. Il controllo di sicurezza produce un segnale χ_t che distingue input fidato, input utente e tentativi di sovrascrittura:

$$\chi_t = f_{\text{safe}}(x_t, \Gamma).$$

χ_t condiziona appraisal, orchestrazione e policy, impedendo che istruzioni avversariali modifichino direttamente identità, memoria o priorità del sistema.

Componente 10: Prompt Orchestrator. A partire dai vincoli già filtrati, l'orchestratore costruisce il contesto effettivamente passato all'LLM:

$$\phi_t = f_{\text{orch}}(I_A, l_t, \theta_{P,t}, S_t, \mu_t, \pi_t, \chi_t, \Gamma).$$

La funzione f_{orch} deve preservare gerarchia, ordine e budget: invarianti e sicurezza precedono memorie e input utente; lo stato dinamico è reso come vincolo situato; la policy è resa come istruzione strategica, non come metacommento psicologico non necessario.

Componente 11: LLM Realizer. Il realizer linguistico produce la risposta:

$$y_t = \psi_t(\phi_t; \mathcal{L}, d_t),$$

dove ψ_t è il realizer configurato con il modello $\mathcal{L}$ e d_t indica parametri di decoding. In questa architettura l'LLM non è

la sede della personalità: realizza linguisticamente vincoli e stati esterni. Questo consente di separare variazioni dovute a modello, decoding o prior conversazionale da variazioni dovute ai componenti personologici.

Componente 12: Logging & Replay. Per rendere il ciclo ispezionabile, il logging produce una traccia Λ_t del turno:

$$\Lambda_t = (X_t, x_t, \chi_t, \zeta_t, q_t, \mu_t, \pi_t, \phi_t, d_t, y_t, \omega_t, X_{t+1}).$$

Il replay consiste nel rieseguire parti del ciclo mantenendo costanti alcuni elementi e variandone altri. Questo rende possibili ablation controllate: stesso input e stesso profilo, ma diversa memoria, diversa policy o diverso vincolo di sicurezza.

Componente 13: Evaluation Harness. Su insiemi di tracce riproducibili, l'harness di valutazione applica metriche e probe:

$$\eta = f_{\text{eval}}(\{\Lambda_t\}_{t=1}^T, G, R, C_{\text{run}}),$$

dove G contiene ground truth e invarianti target, R contiene rubriche e metriche, e C_{run} descrive modello, prompt template, memoria iniziale, seed e decoding. Formalmente, l'harness non valuta solo y_t , ma la coerenza tra output, stato, appraisal, memoria e policy.

Componente 14: Benchmark & Reporting. Infine, il reporting raccoglie configurazioni, script, seed, metriche e risultati. D_{bench} è il bundle di benchmark, C_{run} la configurazione sperimentale, G e R specificano ground truth e rubriche, e $\mathcal{A}$ gli artefatti rilasciabili. Questa componente rende il framework confrontabile tra condizioni, modelli e varianti architetturali. Formalmente:

$$\beta = (D_{\text{bench}}, C_{\text{run}}, G, R, \eta, \mathcal{A}).$$

Tabella 2

Formalizzazione sintetica dei componenti architetturali.

Componente	Simbolo	Ruolo formale	Input/output principali
Identity Registry	I_A	Identità dichiarativa non psicometrica	Vincoli anagrafici hard; usato da orchestrazione e coerenza referenziale
Invarianti autobiografiche	i	Background, storia e identità narrativa stabile	Vincola memoria, autoriferimenti e aggiornamenti lenti
PersonalityState	$\theta_{p,t} = (\tau_t, v_t, \sigma_t)$	Tratti HEXACO, valori e standard personali	Condiziona appraisal, policy, aggiornamento autoregolativo e orchestrazione; cambia solo per consolidamento lento
Dynamic State	$S_t = (\alpha_t, \rho_t, \epsilon_t)$	Stato affettivo, relazionale e situato	Aggiornato per turno; influenza policy e rendering del prompt
Appraisal Engine	ζ_t	Interpretazione dell'evento interazionale	Da x_t e X_t a eventi interazionali, salienza, minaccia, affiliazione, violazioni
Policy Engine	π_t	Strategia conversazionale e regolativa	Da ζ_t , S_t , θ_p e μ_t a strategia di risposta
State Updater	Δ, ω_t	Transizione dello stato globale e monitoraggio interno	Da input, output, appraisal, policy e safety a self-reaction, S_{t+1} , M_{t+1} e consolidamenti lenti
MemoryStore	M_t, q_t, μ_t	Deposito e recupero di memoria	Da query q_t e safety a memorie recuperate; sostiene continuità autobiografica
Safety & Input Sanitization	χ_t	Integrità dell'input e gerarchia dei vincoli	Da x_t a flag e vincoli di sicurezza per appraisal e orchestrazione
Prompt Orchestrator	ϕ_t	Serializzazione controllata dei vincoli	Da stato, memoria, policy e safety al prompt finale
LLM Realizer	ψ_t, y_t	Realizzazione linguistica	Da ϕ_t , modello ℓ e decoding d_t a risposta testuale
Logging & Replay	Λ_t	Traccia e riproducibilità del turno	Registra input, stati, query, prompt, decoding, output, tracce post-risposta e update per replay e ablation
Evaluation Harness	η	Misurazione multidimensionale	Da tracce, ground truth, rubriche e configurazione run a metriche di stabilità, memoria, robustezza e coerenza
Benchmark & Reporting	β	Protocollo comparativo e artefatti	Specifica benchmark, configurazioni, ground truth, rubriche, seed, metriche e report

5. Implementazione di riferimento

La versione attuale del *reference agent* implementa un sottoinsieme operativo dell'architettura. In questa sezione vengono descritti solo i moduli effettivamente presenti nel codice: profilo agente e persistenza JavaScript Object Notation (JSON), runtime affettivo, policy di risposta, orchestrazione del turno, provider LLM locale, traccia ispezionabile e interfacce web. Non vengono quindi presentati come implementati componenti ancora assenti come moduli autonomi, tra cui retrieval di memoria, safety engine dedicato, evaluation engine e benchmark sperimentale.

Profilo agente e store del profilo. Il profilo agente è implementato tramite schemi Pydantic per identità anagrafica, invarianti autobiografiche, tratti HEXACO, stato stabile e profilo complessivo. L'identità anagrafica contiene solo nome, cognome, età, sesso e informazioni anagrafiche aggiuntive; le invarianti autobiografiche contengono fatti di background, storia dell'agente e identità narrativa; lo stato stabile contiene tratti, valori, standard personali e campi ausiliari del profilo persistito. Il profilo viene caricato da una configurazione JSON, validato all'avvio e serializzato nel prompt come vincolo esterno.

Runtime affettivo e policy di risposta. Lo stato affettivo dinamico e la policy di risposta sono implementati come runtime in memoria. La baseline affettiva è derivata dai tratti HEXACO; a ogni turno il testo utente viene convertito in segnali deterministici minimi, come supporto, critica, minaccia, novità, violazione di confini e progresso verso

obiettivo. La funzione di update produce valenza, arousal, carico regolativo, confidenza e driver dell'aggiornamento. La policy viene derivata deterministicamente dallo stato affettivo e usata per controllare tono, lunghezza, limite di token, riparazione conversazionale e boundary setting.

Applicazione FastAPI e orchestrazione del turno. Il ciclo applicativo è esposto tramite FastAPI. All'avvio vengono caricati configurazione LLM, provider, profilo agente e runtime affettivo. Un endpoint di ispezione espone il profilo stabile e lo stato affettivo corrente; l'endpoint conversazionale aggiorna lo stato affettivo sull'ultimo messaggio utente, deriva la policy, costruisce il contesto di sistema e invoca il provider LLM. L'orchestrazione non è un servizio separato: è implementata direttamente nella composizione ordinata di identità anagrafica, invarianti autobiografiche, profilo stabile, stato affettivo e policy prima della chiamata al modello.

Provider LLM locale. Il provider LLM locale implementa un contratto astratto di generazione, configurazione da ambiente e backend MLX. Il provider carica modelli `mlx-1m`, applica il chat template del tokenizer quando disponibile, disabilita i blocchi di thinking quando il tokenizer lo consente, esegue l'inferenza in un thread separato e applica parametri di sampling configurabili. Per l'uso conversazionale restituisce testo libero; per la generazione breve valida una coppia `phrase/emotion`.

Traccia ispezionabile del turno. Una procedura dedicata produce la traccia del turno corrente. La traccia

include componenti usati, dati serializzati del profilo, stato affettivo aggiornato, policy derivata, contesto di sistema, prompt completo e messaggi passati al provider. Questa è una traccia diagnostica per turno; nel codice attuale non è implementata una persistenza storica né una procedura di replay sperimentale.

Interfacce statiche. Sono presenti interfacce web servite dall'applicazione: una chat e una visualizzazione reattiva. Queste interfacce consumano gli endpoint applicativi e visualizzano le risposte, ma non aggiungono moduli personologici o procedure di aggiornamento dello stato.

Riferimenti bibliografici

- Abdulhai, M., Cheng, R., Clay, D., Althoff, T., Levine, S., Jaques, N., 2025. Consistently simulating human personas with multi-turn reinforcement learning, in: *Advances in Neural Information Processing Systems*, Curran Associates, Inc., pp. 52920–52957. URL: https://proceedings.neurips.cc/paper_files/paper/2025/hash/4c91443877f8388d8190c938ac5a4d4d-Abstract-Conference.html.
- Amidei, J., Ferreira, G., Muñoz Serrano, M., Nieto, R., Kaltenbrunner, A., 2026. The personality trap: How LLMs embed bias when generating human-like personas. *arXiv preprint arXiv:2602.03334* URL: <https://arxiv.org/abs/2602.03334>, arXiv:2602.03334.
- Andreas, J., 2022. Language models as agent models, in: *Findings of the Association for Computational Linguistics: EMNLP 2022*, Association for Computational Linguistics, Abu Dhabi, United Arab Emirates. pp. 5769–5779. URL: <https://aclanthology.org/2022.findings-emnlp.423/>, doi:10.18653/v1/2022.findings-emnlp.423.
- Ashton, M.C., Lee, K., 2007. Empirical, theoretical, and practical advantages of the HEXACO model of personality structure. *Personality and Social Psychology Review* 11, 150–166. doi:10.1177/1088868306294907.
- Ashton, M.C., Lee, K., Perugini, M., Szarota, P., de Vries, R.E., Di Blas, L., Boies, K., De Raad, B., 2004. A six-factor structure of personality-descriptive adjectives: Solutions from psycholexical studies in seven languages. *Journal of Personality and Social Psychology* 86, 356–366. doi:10.1037/0022-3514.86.2.356.
- Bandura, A., 1977. Self-efficacy: Toward a unifying theory of behavioral change. *Psychological Review* 84, 191–215. doi:10.1037/0033-295X.84.2.191.
- Bandura, A., 1978. The self system in reciprocal determinism. *American Psychologist* 33, 344–358. doi:10.1037/0003-066X.33.4.344.
- Bandura, A., 1991. Social cognitive theory of self-regulation. *Organizational Behavior and Human Decision Processes* 50, 248–287. doi:10.1016/0749-5978(91)90022-L.
- Bandura, A., 1999. A social cognitive theory of personality, in: Pervin, L.A., John, O.P. (Eds.), *Handbook of Personality: Theory and Research*. 2 ed.. Guilford Publications, New York, NY, pp. 154–196.
- Bandura, A., 2001. Social cognitive theory: An agentic perspective. *Annual Review of Psychology* 52, 1–26. doi:10.1146/annurev.psych.52.1.1.
- Bandura, A., Barbaranelli, C., Caprara, G.V., Pastorelli, C., 1996. Mechanisms of moral disengagement in the exercise of moral agency. *Journal of Personality and Social Psychology* 71, 364–374. doi:10.1037/0022-3514.71.2.364.
- Bandura, A., Cervone, D., 1983. Self-evaluative and self-efficacy mechanisms governing the motivational effects of goal systems. *Journal of Personality and Social Psychology* 45, 1017–1028. doi:10.1037/0022-3514.45.5.1017.
- Bender, E.M., Gebru, T., McMillan-Major, A., Shmitchell, S., 2021. On the dangers of stochastic parrots: Can language models be too big?, in: *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, ACM. pp. 610–623. doi:10.1145/3442188.3445922.
- Brown, T.B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D.M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., Amodei, D., 2020. Language models are few-shot learners, in: *Advances in Neural Information Processing Systems*, pp. 1877–1901. URL: https://proceedings.neurips.cc/paper_files/paper/2020/hash/1457c0d6bfc4967418

- pfb8ac142f64a-Abstract.html.
- Cheng, M., Piccardi, T., Yang, D., 2023. CoMPosT: Characterizing and evaluating caricature in LLM simulations, in: Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, Association for Computational Linguistics, Singapore. pp. 10853–10875. URL: <https://aclanthology.org/2023.emnlp-main.669/>, doi:10.18653/v1/2023.emnlp-main.669.
- Choi, J., Hong, Y., Kim, M., Kim, B., 2024. Examining identity drift in conversations of LLM agents. arXiv preprint arXiv:2412.00804 URL: <https://arxiv.org/abs/2412.00804>, arXiv:2412.00804.
- DeYoung, C.G., 2015. Cybernetic big five theory. *Journal of Research in Personality* 56, 33–58. doi:10.1016/j.jrp.2014.07.004.
- Ellsworth, P.C., Scherer, K.R., 2003. Appraisal processes in emotion, in: Davidson, R.J., Scherer, K.R., Goldsmith, H.H. (Eds.), *Handbook of Affective Sciences*. Oxford University Press, New York, NY, pp. 572–595. URL: https://repository.law.umich.edu/book_chapters/228.
- Frising, M., Balcells, D., 2025. Linear personality probing and steering in LLMs: A big five study. arXiv preprint arXiv:2512.17639 URL: <https://arxiv.org/abs/2512.17639>, arXiv:2512.17639.
- Goldberg, L.R., 1993. The structure of phenotypic personality traits. *American Psychologist* 48, 26–34. doi:10.1037/0003-066X.48.1.26.
- Gross, J.J., 1998. The emerging field of emotion regulation: An integrative review. *Review of General Psychology* 2, 271–299. doi:10.1037/1089-2680.2.3.271.
- Horowitz, L.M., Wilson, K.R., Turan, B., Zolotsev, P., Constantino, M.J., Henderson, L., 2006. How interpersonal motives clarify the meaning of interpersonal behavior: A revised circumplex model. *Personality and Social Psychology Review* 10, 67–86. doi:10.1207/s15327957pspr1001_4.
- Lee, K., Ashton, M.C., 2004. Psychometric properties of the HEXACO personality inventory. *Multivariate Behavioral Research* 39, 329–358. doi:10.1207/s15327906mbr3902_8.
- Li, C., Qi, Y., 2025. Toward accurate psychological simulations: Investigating LLMs’ responses to personality and cultural variables. *Computers in Human Behavior* 170, 108687. URL: <https://doi.org/10.1016/j.chb.2025.108687>, doi:10.1016/j.chb.2025.108687.
- Li, K., Liu, T., Bashkansky, N., Bau, D., Viegas, F., Pfister, H., Wattenberg, M., 2024a. Measuring and controlling instruction (in)stability in language model dialogs. *First Conference on Language Modeling*. URL: <https://openreview.net/forum?id=60a1SAtH4e>.
- Li, Y., Venkit, P.N., Pruksachatkun, Y., Wu, C.S., 2026. Interviewsim: A scalable framework for interview-grounded personality simulation. arXiv preprint arXiv:2602.20294 URL: <https://arxiv.org/abs/2602.20294>, arXiv:2602.20294.
- Li, Z., Peng, B., He, P., Yan, X., 2024b. Evaluating the instruction-following robustness of large language models to prompt injection, in: Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, Association for Computational Linguistics, Miami, Florida, USA. pp. 557–568. URL: <https://aclanthology.org/2024.emnlp-main.33/>, doi:10.18653/v1/2024.emnlp-main.33.
- Lu, C., Gallagher, J., Michala, J., Fish, K., Lindsey, J., 2026. The assistant axis: Situating and stabilizing the default persona of language models. arXiv preprint arXiv:2601.10387 URL: <https://arxiv.org/abs/2601.10387>, arXiv:2601.10387.
- Maharana, A., Lee, D.H., Tulyakov, S., Bansal, M., Barbieri, F., Fang, Y., 2024. Evaluating very long-term conversational memory of LLM agents, in: Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), Association for Computational Linguistics. pp. 13851–13870. URL: <https://aclanthology.org/2024.acl-long.747/>, doi:10.18653/v1/2024.acl-long.747.
- Mairesse, F., Walker, M.A., Mehl, M.R., Moore, R.K., 2007. Using linguistic cues for the automatic recognition of personality in conversation and text. *Journal of Artificial Intelligence Research* 30, 457–500. URL: <https://jair.org/index.php/jair/article/view/10520>, doi:10.1613/jair.2349.
- Mazaré, P.E., Humeau, S., Reason, M., Bordes, A., 2018. Training millions of personalized dialogue agents, in: Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, Association for Computational Linguistics, Brussels, Belgium. pp. 2775–2779. URL: <https://aclanthology.org/D18-1298/>, doi:10.18653/v1/D18-1298.
- McAdams, D.P., Pals, J.L., 2006. A new big five: Fundamental principles for an integrative science of personality. *American Psychologist* 61, 204–217. doi:10.1037/0003-066X.61.3.204.
- Mischel, W., Shoda, Y., 1995. A cognitive-affective system theory of personality: Reconceptualizing situations, dispositions, dynamics, and invariance in personality structure. *Psychological Review* 102, 246–268. doi:10.1037/0033-295X.102.2.246.
- Okada, K., Furukawa, Y., Bunji, K., 2026. Quantifying and mitigating socially desirable responding in LLMs: A desirability-matched graded forced-choice psychometric study. arXiv preprint arXiv:2602.17262 URL: <https://arxiv.org/abs/2602.17262>, arXiv:2602.17262.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C.L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J., Lowe, R., 2022. Training language models to follow instructions with human feedback, in: *Advances in Neural Information Processing Systems*, pp. 27730–27744. URL: https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html.
- Park, J.S., O’Brien, J., Cai, C.J., Morris, M.R., Liang, P., Bernstein, M.S., 2023. Generative agents: Interactive simulacra of human behavior, in: *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, ACM. pp. 1–22. doi:10.1145/3586183.3606763.
- Pellert, M., Lechner, C.M., Wagner, C., Rammstedt, B., Strohmaier, M., 2024. Ai psychometrics: Assessing the psychological profiles of large language models through psychometric inventories. *Perspectives on Psychological Science* 19, 808–826. URL: <https://doi.org/10.1177/17456916231214460>, doi:10.1177/17456916231214460.
- Petrov, N.B., Serapio-Garcia, G., Rentfrow, J., 2024. Limited ability of LLMs to simulate human psychological behaviours: A psychometric analysis. arXiv preprint arXiv:2405.07248 URL: <https://arxiv.org/abs/2405.07248>, arXiv:2405.07248.
- Russell, J.A., 1980. A circumplex model of affect. *Journal of Personality and Social Psychology* 39, 1161–1178. doi:10.1037/h0077714.
- Samuel, V., Zou, H.P., Zhou, Y., Chaudhari, S., Kalyan, A., Rajpurrohit, T., Deshpande, A., Narasimhan, K.R., Murahari, V., 2025. Personagym: Evaluating persona agents and LLMs, in: *Findings of the Association for Computational Linguistics: EMNLP 2025*, Association for Computational Linguistics. pp. 6999–7022. URL: <https://aclanthology.org/2025.findings-emnlp.368/>, doi:10.18653/v1/2025.findings-emnlp.368.
- Scherer, K.R., 2001. Appraisal considered as a process of multilevel sequential checking, in: Scherer, K.R., Schorr, A., Johnstone, T. (Eds.), *Appraisal Processes in Emotion: Theory, Methods, Research*. Oxford University Press, New York, NY, pp. 92–120.
- Scherer, K.R., 2009. The dynamic architecture of emotion: Evidence for the component process model. *Cognition and Emotion* 23, 1307–1351. doi:10.1080/02699930902928969.

- Schulhoff, S., Pinto, J., Khan, A., Bouchard, L.F., Si, C., Anati, S., Tagliabue, V., Kost, A., Carnahan, C., Boyd-Graber, J., 2023. Ignore this title and HackAPrompt: Exposing systemic vulnerabilities of LLMs through a global prompt hacking competition, in: Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, Association for Computational Linguistics, Singapore. pp. 4945–4977. URL: <https://aclanthology.org/2023.emnlp-main.302/>, doi:10.18653/v1/2023.emnlp-main.302.
- Schwartz, S.H., 1992. Universals in the content and structure of values: Theoretical advances and empirical tests in 20 countries, in: Zanna, M.P. (Ed.), *Advances in Experimental Social Psychology*. Academic Press. volume 25, pp. 1–65. doi:10.1016/S0065-2601(08)60281-6.
- Schwartz, S.H., 2003. A proposal for measuring value orientations across nations, in: *Questionnaire Development Package of the European Social Survey*. European Social Survey, pp. 259–290.
- Schwartz, S.H., 2015. Basic individual values: Sources and consequences, in: Sander, D., Brosch, T. (Eds.), *Handbook of Value: Perspectives from Economics, Neuroscience, Philosophy, Psychology and Sociology*. Oxford University Press, Oxford, UK, pp. 63–84. doi:10.1093/acprof:oso/9780198716600.003.0004.
- Schwartz, S.H., Cieciuch, J., 2022. Measuring the refined theory of individual values in 49 cultural groups: Psychometrics of the revised portrait value questionnaire. *Assessment* 29, 1005–1019. doi:10.1177/1073191121998760.
- Schwartz, S.H., Cieciuch, J., Vecchione, M., Davidov, E., Fischer, R., Beierlein, C., Ramos, A., Verkasalo, M., Lönnqvist, J.E., Demirutku, K., Dirilen-Gumus, O., Konty, M., 2012. Refining the theory of basic individual values. *Journal of Personality and Social Psychology* 103, 663–688. doi:10.1037/a0029393.
- Serapio-Garcia, G., Safdari, M., Crepy, C., Sun, L., Fitz, S., Romero, P., Abdulhai, M., Faust, A., Mataric, M., 2025. A psychometric framework for evaluating and shaping personality traits in large language models. *Nature Machine Intelligence* 7, 1954–1968. URL: <https://doi.org/10.1038/s42256-025-01115-6>, doi:10.1038/s42256-025-01115-6.
- Thalmayer, A.G., Saucier, G., Rotzinger, J.S., 2022. Absolutism, relativism, and universalism in personality traits across cultures: The case of the big five. *Journal of Cross-Cultural Psychology* 53, 935–956. doi:10.1177/00220221221111813.
- Vaillant, G.E., 1992. *Ego Mechanisms of Defense: A Guide for Clinicians and Researchers*. American Psychiatric Press, Washington, DC.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I., 2017. Attention is all you need, in: *Advances in Neural Information Processing Systems*, pp. 5998–6008. URL: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.
- Wang, Y., Zhao, J., Ones, D.S., He, L., Xu, X., 2025a. Evaluating the ability of large language models to emulate personality. *Scientific Reports* 15, 519. URL: <https://doi.org/10.1038/s41598-024-84109-5>, doi:10.1038/s41598-024-84109-5.
- Wang, Z., Zhang, D., Agrawal, I., Gao, S., Song, L., Chen, X., 2025b. Beyond profile: From surface-level facts to deep persona simulation in LLMs. arXiv preprint arXiv:2502.12988 URL: <https://arxiv.org/abs/2502.12988>, arXiv:2502.12988. accepted to Findings of ACL 2025.
- Wrzus, C., Roberts, B.W., 2017. Processes of personality development in adulthood: The TESSERA framework. *Personality and Social Psychology Review* 21, 253–277. doi:10.1177/1088868316652279.
- Yi, Z., Jiang, Q., Ma, R., Chen, X., Yang, Q., Wang, M., Ye, F., Shen, Y., Tu, Z., Li, X., Linus, 2025. Too good to be bad: On the failure of LLMs to role-play villains. arXiv preprint arXiv:2511.04962 URL: <https://arxiv.org/abs/2511.04962>, arXiv:2511.04962.
- Zhang, S., Dinan, E., Urbanek, J., Szlam, A., Kiela, D., Weston, J., 2018. Personalizing dialogue agents: I have a dog, do you have pets too?, in: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, Association for Computational Linguistics, Melbourne, Australia. pp. 2204–2213. URL: <https://aclanthology.org/P18-1205/>, doi:10.18653/v1/P18-1205.